

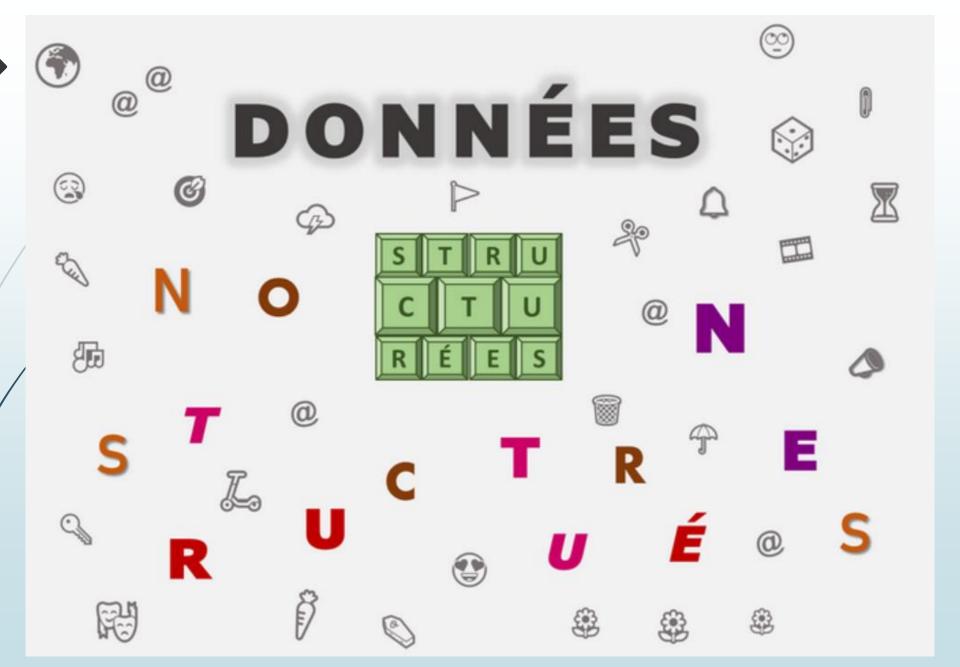
Université Benyoucef Benkhadda - Alger 1 Faculté des Sciences - Département MI

# Données Semi Structurées 3.Schema de Xml DTD – Xml schema (XSD)

Présenté par : Mme. YDROUDJ

a\_ydroudj@esi.dz

3ème Année Licence : SI/ISIL



## Plan du Cours

- Document valide
- Pourquoi valider un document Xml
- DTD : informations générales
- 🗖 DTD : Rôle principal
- Déclaration de la DTD
- Définition des éléments
- Définition des attributs
- Définition des entités
- Exercices

### Document XML valide

Un document peut être valide par rapport à un schéma qui définit un vocabulaire et une structure.

Qu'est ce qu'un schéma?

Ensemble de contraintes/règles décrivant décrivent la grammaire utilisable dans un document XML

DTD (Document Type Definitions)

**Relax NG** 

Validation

Schematron

XML schema

Valider en comparant chaque document XML à l'aide d'un outil de validation disponible en :

- Mode ligne de commande : xmllint, xmlstarlet, etc.
- En ligne: <u>validator.w3.org</u>
- Intégré par défaut dans des éditeurs xml : xmlSpy

## **Document XML valide**

- Pourquoi valider?
- Uniformité « grammaire pour un groupes de documents »
- Si plusieurs personnes travaillent sur un même document XML, la DTD garantit que tout le monde respectera la structure définie.
- Rendre plusieurs documents XML utilisables par un même logiciel de traitement (exemple
   ERP dans une banque : transactions, marchés, conventions, etc.)

La validation indique que soit le document est valide, soit il contient des erreurs comme : tel attribut de tel élément contient une valeur interdite par telle contrainte, il manque tel sous-élément dans tel élément, etc.

## **DTD**: informations générales

DTD : description formelle (la grammaire) de la structure du document

### Une DTD peut être :

- Locale au document (avec mode standalone=yes),
- Importée dans le document (avec mode standalone=no)
- Mixte (la partie interne est lue en premier, standalone=no)
- La DTD est facultative

Mais/

Un document qui déclare une DTD doit s'y conformer (on parle de la validité). Dans un contexte professionnel, on ne peut pas s'en passer.

Contenu principal

- Déclaration de chaque élément et de son contenu <!ELEMENT ....
- Déclaration des attributs possibles d'un élément <!ATTLIST ...>
- Déclaration des entités possibles <!ENTITY ...>

Les DTD sont issues de la norme SGML et n'ont pas la syntaxe XML.

Les DTD contiennent des déclarations des:

- Éléments
- Attributs
- Entités

L3 SI/ISIL-2021 Mme.YDROUDJ

## **DTD : Rôle principal**



## DTD: interne, externe et publique, mixte

Déclaration de la DTD dans le document XML

La référence a la DTD doit être placée au début du fichier après le prologue :

Interne au document XML (1): <!DOCTYPE commission [...instructions...]>

Externe au document, dans un fichier "voisin" (2):

<!DOCTYPÉ commission SYSTEM "(http://x.y/)exemple.dtd">

Externé au document, publique (sur le web) (3) :

\*IDOCTYPE commission PUBLIC "ident-connu" "URL-sinon">

n peut combiner 1+2 ou 1+3 pour avoir une DTD mixte.

DTD externe: permet la réutilisation pour d'autres documents XML

DTD externe publique: définit un standard pour certains documents (CV, facture, publications, ...)

Dans ce cas, les déclarations internes sont lues avant la DTD externe pour ne pas avoir de conflits.

L3 SI/ISIL-2021 Mme.YDROUDJ

Syntaxe: <!ELEMENT le\_nom (le\_contenu) type\_prédéfini>

- Le contenu contient :
- Soit une séquence de sous éléments :
  - indique quel(s) élément(s) compose(nt) l'élément de la balise
  - liste de sous éléments séparés par une virgule
  - Itous Jes éléments devront apparaître dans l'ordre prévu

Un Auteur doit avoir un Nom puis un Prénom :



<!ELEMENT Auteur (Nom, Prénom)>

- Soit un Choix à prendre parmi une liste de sous éléments :
  - indique quel(s) élément(s) compose(nt) le modèle
    - liste d'éléments séparés par une barre verticale
    - un seul élément de la liste devra apparaître et pas les deux

Une coordonnée peut être un numéro de tel ou une adresse mail :



<!ELEMENT coordonnée (numTel email)>

Syntaxe: <!ELEMENT le\_nom (le\_contenu) type\_prédéfini>

- **■** Type prédéfini contient :
- ANY: signifie que l'élément peut contenir n'importe quels
- éléments (définis dans la DTD) et textes (leur ordre d'apparition
- et leur nombre ne seront pas testés),
- **EMPTY**: signifie que l'élément doit être vide,
- #PCDATA: signifie que l'élément ne contient que des textes

### son utilisation:

10

- NY et EMPTY : sans parenthèses
- \* \( \) (\) (\) CDATA): avec parenthèses

<!ELEMENT Nom (#PCDATA)>

<!ELEMENT img EMPTY>

<!ELEMENT adresse ANY>

### Quelques détails sur les sous éléments

11

Une liste ordonnée déclarée dans l'élément père, dans laquelle chaque sous-élément peut être suivi d'un suffixe qui indique la fréquence de son apparition :

Opérateur	Cardinalités	Signification	Exemple
	(1,1)	Obligatoire (par défaut) : doit apparaître une et une seule fois	A
?	(0,1)	Optionnel : doit apparaître zéro ou une seule fois	A?
*	(0,n)	Multiple : peut apparaître plusieurs fois ou ne pas apparaître	<b>A*</b>
+	(1,n)	Multiple obligatoire : doit apparaître au moins une fois	<b>A</b> +
I		L'élément A ou B peuvent être présents mais pas les deux, ordre n'est pas important	A B
,		L'élément A doit être présent suivi de l'élément B	A,B
O		Permettent de regrouper des éléments afin de leur appliquer les autres opérateurs	(A,B)+

**Exemple1**: Soit la DTD suivante

<!DOCTYPE INVENTAIRE [
<!ELEMENT INVENTAIRE (TITRE)>
<!ELEMENT TITRE (#PCDATA | SOUSTITRE)\*>
<!ELEMENT SOUSTITRE (#PCDATA)> ]>

Elle signifie que pour un élément TITRE, on peut avoir :

- soit des données caractères
- soit un élément SOUSTITRE

Et ceci zéro, une ou plusieurs fois mais notre document XML ne peut contenir qu'un seul « TITRE ».

```
<INVENTAIRE>
<TITRE>
Thorgal
<SOUSTITRE>Et la chambre des secrets</SOUSTITRE>
</TITRE>
</INVENTAIRE>
```

```
<INVENTAIRE>
<TITRE>
<SOUSTITRE>Et la chambre des secrets</SOUSTITRE>
Thorgal
</TITRE>
</INVENTAIRE>
```

**Exemples:** Soit la DTD suivante

<!DOCTYPE INVENTAIRE [
<!ELEMENT INVENTAIRE (TITRE)>
<!ELEMENT TITRE (#PCDATA | SOUSTITRE)\*>
<!ELEMENT SOUSTITRE (#PCDATA)> ]>

Elle signifie que pour un élément TITRE, on peut avoir :

- soit des données caractères
- soit un élément SOUSTITRE

Et ceci zéro, une ou plusieurs fois mais notre document XML ne peut contenir qu'un seul « TITRE ».

```
<INVENTAIRE>
<TITRE>
Thorgal
</TITRE>
</INVENTAIRE>
```

```
<INVENTAIRE>
<TITRE>
<SOUSTITRE>Et la chambre des secrets</SOUSTITRE>
<SOUSTITRE>la grande surprise</SOUSTITRE>
</TITRE>
</INVENTAIRE>
```

**Exemples:** Soit la DTD suivante

```
<!DOCTYPE INVENTAIRE [
<!ELEMENT INVENTAIRE (TITRE)>
<!ELEMENT TITRE (#PCDATA | SOUSTITRE)*>
<!ELEMENT SOUSTITRE (#PCDATA)> ]>
```

<INVENTAIRE>
<TITRE>
</TITRE>
</INVENTAIRE>

Elle signifie que pour un élément TITRE, on peut avoir :

- soit des données caractères
- soit un élément SOUSTITRE

Et ceci zéro, une ou plusieurs fois mais notre document XML ne peut contenir qu'un seul « TITRE ».

```
<INVENTAIRE>
<TITRE>
Thorgal
<SOUSTITRE>Et la chambre des secrets</SOUSTITRE>
thorgal
<SOUSTITRE>la grande surprise</SOUSTITRE>
</TITRE>
</INVENTAIRE>
```

### Exemple 2 : Soit la DTD suivante

```
<!DOCTYPE INVENTAIRE [
<!ELEMENT INVENTAIRE (TITRE)*>
<!ELEMENT TITRE (#PCDATA | SOUSTITRE)>
<!ELEMENT SOUSTITRE (#PCDATA)> ]>
```

Elle signifie que pour un élément TITRE, on peut avoir :

- soit des données caractères
- soit un élément SOUSTITRE

Et ceci une et une seule fois (il s'agit donc d'un OU exclusif).

Mais le documents XML peut contenir zéro, un ou plusieurs « TITRE ».

```
<INVENTAIRE>
<TITRE>
Thorgal
<SOUSTITRE>Et lla chambre des secrets</SOUSTITRE>
</TITRE>
</INVENTAIRE>
```

```
<INVENTAIRE>
<TITRE>
<SOUSTITRE>La grande surprise</SOUSTITRE>
Thorgal
</TITRE>
</INVENTAIRE>
```

### Exemple 2 : Soit la DTD suivante

<!DOCTYPE INVENTAIRE [
<!ELEMENT INVENTAIRE (TITRE)\*>
<!ELEMENT TITRE (#PCDATA | SOUSTITRE)>
<!ELEMENT SOUSTITRE (#PCDATA)> ]>

Elle signifie que pour un élément TITRE, on peut avoir :

- soit des données caractères
- soit un élément SOUSTITRE

Et ceci une et une seule fois (il s'agit donc d'un OU exclusif).

Mais le documents XML peut contenir zéro, un ou plusieurs « TITRE ».

<INVENTAIRE>
<TITRE>
Thorgal
</TITRE>
</INVENTAIRE>

<INVENTAIRE>
<TITRE>
<SOUSTITRE>la grande surprise</SOUSTITRE>
<SOUSTITRE>Les loups de la jungle</SOUSTITRE>
</TITRE>
</INVENTAIRE>

### Exemple 2 : Soit la DTD suivante

<!DOCTYPE INVENTAIRE [
<!ELEMENT INVENTAIRE (TITRE)\*>
<!ELEMENT TITRE (#PCDATA | SOUSTITRE)>
<!ELEMENT SOUSTITRE (#PCDATA)> ]>

Elle signifie que pour un élément TITRE, on peut avoir :

- soit des données caractères
- soit un élément SOUSTITRE

Et ceci une et une seule fois (il s'agit donc d'un OU exclusif).

Mais le documents XML peut contenir zéro, un ou plusieurs « TITRE ».

```
<INVENTAIRE>
<TITRE>
</TITRE>
</INVENTAIRE>
```

```
<INVENTAIRE>
<Inventaire>
<Intro
<pre><Inventaire>

<pr
```

### 18

### DTD: déclaration des sous éléments

### **Exemple 3:** Soit la DTD suivante

```
<!DOCTYPE INVENTAIRE [
<!ELEMENT INVENTAIRE (TITRE)>
<!ELEMENT TITRE (#PCDATA, SOUSTITRE)*>
<!ELEMENT SOUSTITRE (#PCDATA)> ]>
```

Elle signifie que pour un élément TITRE, on doit avoir :

- des données caractères

### ET

- un élément SOUSTITRE

Et ceci zéro, une ou plusieurs fois

Mais notre document XML ne peut contenir qu'un seul TITRE.

```
<INVENTAIRE>
<ITTRE>
Thorgal
<SOUSTITRE>Et la chambre des secrets</SOUSTITRE>
</TITRE>
</INVENTAIRE>
```

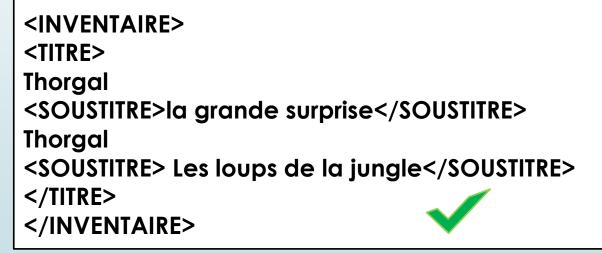
```
<INVENTAIRE>
<TITRE>
<SOUSTITRE>La grande surprise</SOUSTITRE>
Thorgal
</TITRE>
</INVENTAIRE>
```

### Exemple 3:

<INVENTAIRE>
<TITRE>
<SOUSTITRE>La grande surprise</SOUSTITRE>
<SOUSTITRE>Les loups de la jungle</SOUSTITRE>
</TITRE>
</INVENTAIRE>

<INVENTAIRE>
<TITRE>
</TITRE>
</INVENTAIRE>

```
<INVENTAIRE>
<TITRE>
Thorgal
</TITRE>
</INVENTAIRE>
```



### **Exemple 4 : Soit la DTD suivante**

<!DOCTYPE INVENTAIRE [</pre> <!ELEMENT INVENTAIRE (TITRE)\*> <!ELEMENT TITRE (#PCDATA, SOUSTITRE)> <!ELEMENT SOUSTITRE (#PCDATA)> ]>

Elle signifie que pour un élément TITRE, on doit avoir :

- des données caractères

### ET

- un élément SOUSTITRE

Et ceci une et une seule fois (il s'agit donc d'un ET exclusif)

Mais le document XML peut contenir zéro, un ou plusieurs « TITRE ».

```
<INVENTAIRE>
<TITRE>
Thorgal
<SOUSTITRE>Et la grande surprise</SOUSTITRE>
</TITRE>
</INVENTAIRE>
```

```
<INVENTAIRE>
<TITRF>
<SOUSTITRE>La grande surprise</SOUSTITRE>
Thorgal
</TITRE>
</INVENTAIRE>
```

### Exemple 4:

21

- <INVENTAIRE>
  <TITRE>
  <SOUSTITRE>La grande surprise</SOUSTITRE>
  <SOUSTITRE>Les loups de la jungle</SOUSTITRE>
  </TITRE>
  </INVENTAIRE>
  - <INVENTAIRE>
    <TITRE>
    Thorgal
    </TITRE>
    </INVENTAIRE>



<INVENTAIRE>
<TITRE>
Thorgal
<SOUSTITRE>la grande surprise</SOUSTITRE>
Thorgal
<SOUSTITRE> Les loups de la jungle</SOUSTITRE>
</TITRE>
</TITRE>
</INVENTAIRE>

## DTD: déclaration des attributs

Syntaxe: <!ATTLIST nom-element

nom-attribut1 type-att declaration-defaut nom-attribut2 type-att declaration-defaut nom-attribut3 type-att declaration-defaut

- Chaque attribut défini dans la liste possède un nom et un type.
- Déclaration par défaut d'un attribut peut être :
- #REQUIRED : Une valeur doit être affectée à l'attribut (obligatoire).
- #IMPLIED : l'attribut est facultatif (on peut inclure ou non l'attribut dans un élément de type associé)
- XED : valeur par défaut (et uniquement celle-là)
- Valeur': Ou encore directement une valeur par défaut entre guillemets

	Туре	Description
	CDATA	Chaînes de caractères non analysées par le parseur.
	Type énuméré (Valeur  ValeurN)	Déclare une liste de valeurs à utiliser, une seule est choisie sur la liste.
	ENTITY	Correspond à une entité déclarée dans la DTD.
	ENTITIES	Correspond à la déclaration de plusieurs entités séparées par des espaces blancs dans la DTD.
	ID	L'attribut en question est un <i>identifiant</i> dans le fichier XML. La valeur d'un attribut de type ID ne peut pas être utilisée deux fois dans le même document(Principe de la clé primaire). Il y a au plus un attribut de type ID par élément
	IDREF	L'attribut en question correspond à la valeur d'un attribut ID déclaré précédemment. ( principe de la clé étrangère)
	IDREFS	Correspond aux valeurs de plusieurs attributs ID séparés par un espace blanc.
	NMTOKEN	L'attribut prend un nom XML, sa valeur doit contenir des caractères d'unité lexicale : Caractères alphabétiques accentués , Chiffres , Caractères : et Caractères des autres langues non romanes
	NMTOKENS	invoque plusieurs tokens XML séparés par des espaces blancs.

L3 SI/ISIL-2021 Mme.YDROUDJ

**Déclaration-défaut Exemples:** Type chaine attribut (présence obligatoire) de caractères CDATA: <!ATTLIST image source CDATA #REQUIRED <image source="bubulle.jpg"</pre> hauteur CDATA #REQUIRED largeur="10cm" élément largeur CDATA #REQUIRED hauteur="5cm" texte CDATA #IMPLIED texte="mon livre vert"/>

### • Énumération:

<!ATTLIST date mois ( janvier | février | mars | avril | mai | juin | juillet | août | septembre | octobre | novembre | decembre ) #REQUIRED >



<date mois="juin"/>

Chaque valeur de la liste doit respecter la syntaxe

### **Exemples:**

ID, IDREF, IDREFS:

```
<!ELEMENT user (#PCDATA)>
<!ATTLIST user id ID #REQUIRED>
<!ELEMENT project (#PCDATA)>
<!ELEMENT manager (#PCDATA)>
<!ATTLIST manager matri ID #REQUIRED>
<!ATTLIST project users IDREFS #REQUIRED>
```

```
<user id="u1" />XX</user>
<user id="u2" />YY</user>
<user id="u3"/>ZZ</user>
<manager matri="mat1"/>ZZ</manager>
<project users="mat1 u1 u2">Foo</project>
<project users="u2 u3">Bar</project>
<project users="u1 u2 u3">Any</project></project>
```

<!ATTLIST a id ID #IMPLIED name ID #IMPLIED >



<!ATTLIST a id ID #IMPLIED name NMTOKEN #IMPLIED >



```
<a name="fichier1.pdf" id="link">fichier 1</a><a name="fichier2.pdf" id="link">fichier 2</a>
```



<a name="fichier1.htm" id="link1">fichier 1</a>
<a name="fichier2.htm" id="link2">fichier 2</a>

### **Exemples:**

NMTOKEN, NMTOKENS:

<!ATTLIST user date\_connex NMTOKEN #REQUIRED>

<user date\_connex="02-09-2020"/>

<!ATTLIST user date\_connex NMTOKENS #REQUIRED>

<user date\_connex="02-09-2020 13:23:45s"/>

<!ELEMENT exo (#PCDATA)>
<!ATTLIST exo niveau NMTOKENS #IMPLIED>

<exo niveau="facile"> série des exercices <XML>
</exo>
<exo niveau="difficile facultatif"> exercice/1

### **Exemples:**

- Type Notation:
- Une notation décrit le format d'une donnée qui ne peut pas être analysée (contenu non xml tel que graphique, multimédia, films FLASH, etc.), ou bien identifie le programme utilisé pour traiter un format particulier.
- <image source="toile.gif"> : utilisant une NOTATION, permettra de faire savoir à l'analyseur syntaxique XML que le contenu d'attribut source ne doit pas seulement être interprété comme une simple chaîne de caractères mais comme référence d'un fichier externe
- La valeur d'un attribut de type NOTATION est le nom d'une des notations déclarées dans la DTD et énumérées pour l'attribut.

\$yntaxe : <!NOTATION nom SYSTEM "url\_emplacement\_notation">

<!NOTATION nom PUBLIC "url\_associe">

### **Exemples:**

Type Notation:



```
<image source="photo.jpg"
largeur="10cm"
hauteur="5cm"
texte="mon poisson rouge"
type="jpeg"/>
```

### **Exemples:**

- Entity, Entities:
- plusieurs classifications : interne ou externe, analysable ou non analysable, générale ou paramètre.
- 1- Interne ou externe : suivant sa localisation par rapport au document XML (déjà vue dans le chapitre 2)
  - 2- Analysable ou non analysable : suivant le contenu de l'entité
- entité analysable (parsed entity ou contenu xml) : elles ne peuvent contenir que des caractères (texte). Le contenu est appelé texte de remplacement.
- l'entité non analysable (unparsed entity ou contenu non xml) : sont des ressources qui peuvent contenir tout type de données (fichier, images).
- 3- générale ou paramètre : suivant son usage comme étant un contenu dans le document xml ou comme une partie à remplacer dans la DTD.
- Nous verrons ici uniquement les entités externes non parsées et les entités paramètres (les autres voir chapitre2)

Entité externe non analysable par xml : Comme déclaration des images

La valeur d'un attribut de type ENTITY comme l'attribut source de type ENTITY, est le nom d'une entité non parsée qui doit être déclarée dans la DTD

photo est remplacée par "photo.jpg" dont le type est jpeg définit dans la notation



<image source="photo"
largeur="10cm"
hauteur="5cm"
texte="mon poisson rouge"/>

Entité paramètre (à remplacer dans les DTD):

```
syntaxe: <!ENTITY %exempl "cours et TP"> Appel : %exempl;
```

- Différence avec les entités générales :
- Appel avec le signe % au lieu de &
- Appel uniquement dans la DTD et jamais dans le contenu principal du document
- Permet de factoriser les définitions d'élément
- Une entité paramètre doit toujours être déclarée avant d'être appelée

### Rôle principal:

Limiter les répétitions de blocs de définition

```
<!ENTITY % type_defaut "CDATA"> <!ATTLIST chapitre titre %type_defaut; #REQUIRED>
```

### 3-Entité paramètre (dans les DTD) : Exemple

```
<!ELEMENT dauphin (nom, taille, poids, date-naissance, commentaire?)>
<!ATTLIST dauphin id ID #REQUIRED
                espèce CDATA #IMPLIED
               nom-savant CDATA #IMPLIED
               photo ENTITY #IMPLIED
<!ELEMENT baleine (nom, taille, poids, date-naissance, commentaire?)>
<!ATTLIST baleine id ID #REQUIRED
                espèce CDATA #IMPLIED
                nom-savant CDATA #IMPLIED
                photo ENTITY #IMPLIED
```

```
<!ENTITY % animal "nom, taille, poids, date-naissance, commentaire?">
<!ENTITY % animal-attr "id ID #REQUIRED
                      espèce CDATA #IMPLIED
                      nom-savant CDATA #IMPLIED
                      photo ENTITY #IMPLIED
<!ELEMENT dauphin (%animal;)>
<!ATTLIST dauphin %animal-attr;>
<!ELEMENT baleine (%animal;)>
<!ATTLIST baleine %animal-attr:>
```

Entity, Entities: Entité interne <!DOCTYPE Université [</pre> générale <!ENTITY UA1 "Université Alger1"> <!ENTITY UA1Desc SYSTEM "http://www.univ-</pre> alger1.dz/description.xml"> <!ENTITY prof "Pr.X"> <!ENTITY % spec "(mathématiques | Informatique)"> <!ENTITY explication SYSTEM "annexe1.xml"> <!ELEMENT dept %spec; #REQUIRED> ]> <Université> <nom>&UA1;</nom> <directeur>&prof;</directeur> <dept> Informatique</dept> <desc>&explication;</desc> </Université>

Entité externe

Entité paramètre <université>
<nom> Université Alger 1</nom>
<directeur> Pr.X</directeur>
<dept> Informatique </dept>
<desc> Tout le contenu du fichier
annexe1.xml ...</desc>

</université>

### 34 DTD: Limites

- DTD permet d'exprimer des contraintes assez basiques
- Liste des éléments et de leurs attributs
- Règles de structuration des éléments

### Mais:

- Impossible de typer réellement les attributs
- Pas de contrainte de longueur de champs
- Il ne peut y avoir deux éléments de même nom dans deux contextes différents
- Pas d'héritage possible entre éléments : notation lourde
- Ras de prise en compte des espaces de noms



Autres langages de schéma plus complets, par ex. XML Schema

## 35 DTD Vs XML Schema

DTD	XML schema
N'est pas une syntaxe XML	Basé sur la syntaxe XML
Difficile à étendre	Facilement extensible
Données textuelles non typées	Supporte les types de données
Ne permet pas de spécifier exactement le nombre d'occurrences d'un élément	Permet de spécifier exactement le nombre d'occurrences d'un élément
Ne supporte pas les espaces de noms	Supporte les espaces de noms

Malheureusement, par contrainte du Temps, le XML schema ne va pas être traité pour cette année.